

Control Barrier Function을 적용한 개입학습 기반 안전 강화학습

이형준^{1*}, 김민섭², 김지본¹, 김종한¹인하대학교 항공우주공학과 및 우주항공시스템융합전공¹, 인하대학교 컴퓨터공학과²

Intervention Learning-Based Safe Reinforcement Learning Using Control Barrier Functions

Hyeong Jun Lee^{1*}, Min Sup Kim², Jibon Kim¹, Jong-Han Kim¹

Key Words : Safe Reinforcement Learning(안전강화학습), Control Barrier Function(제어 장벽 함수), Intervention Learning(개입 학습), Collision Avoidance(충돌 회피)

서론

최근 무인기 및 자율비행 시스템에 강화 학습을 적용한 연구가 활발히 진행되고 있다. 안전성(Safety)을 보장하기 위해 CBF(Control Barrier Function) 기반 안전 강화학습 기법이 널리 사용되고 있으며⁽¹⁾, 정책 출력이 CBF-QP(Quadratic Programming)에 의해 수정되는 구조에서 행동 불일치(action mismatch)가 발생한다. 기존 연구들은 개입 데이터를 활용하거나 미분 가능한 CBF-QP 레이어 도입⁽²⁾을 통해 완화하고자 하였으나, 학습 구조의 복잡성을 증가시키며 안전 동작을 정책에 완전히 내재화하지 못하는 단점이 있다.

본 논문은 CBF-QP가 포함된 시스템을 하나의 환경으로 구성하여 정책을 먼저 학습한 뒤, MILE(Model-based Intervention Learning)⁽³⁾ 기반 개입 학습을 통해 남은 행동 불일치 구간을 선택적으로 보정하는 구조를 제안한다. 제안한 구조의 유효성을 드론 시뮬레이션 환경에서 검증하였다.

본론

시스템 설정

본 연구는 PyBullet 기반 드론 환경에서 장애물을 회피하며, 목표 지점에 도달하는 문제를 다룬다. 정책은 정규화된 2차원 속도벡터 $a \in [-1, 1]^2$ 를 출력하며, 최대 속도 V_{max} 를 곱해 속도 명령 u_{nom} 을 산출한다.

드론의 동역학은 1차 지연 모델로 근사하며, 식 (1)과 같다.

$$\dot{p} = v, \quad \dot{v} = \frac{1}{\tau}(u - v) \quad (1)$$




Fig. 1. PyBullet drone environment

여기서 $p = [x, y]^T$, $v = [v_x, v_y]^T$ 이며 τ 는 속도 제어기의 시상수를 의미한다.

CBF 기반 안전 필터 구현

정책이 출력한 속도 명령 u_{nom} 은 안전 제약을 위반할 수 있으므로, 매 제어 주기마다 CBF 기반 안전 필터를 적용하여 실제 적용 입력 u_{safe} 를 계산한다.

장애물 중심을 c , 안전 반경을 r_0 라 할 때 barrier 함수는 식 (2)와 같이 정의한다. 식 (1)에 정의된 동역학에 대한 cascade CBF⁽⁴⁾ 조건은 식 (3)과 같이 속도 입력 u 에 대해 선형 부등식 형태로 정리된다.

$$h(p) = \|p - c\|^2 - r_0^2 \quad (2)$$

$$\ddot{h} + (k_1 + k_2)\dot{h} + k_1 k_2 h \geq 0 \Rightarrow A(s)u \geq b(s) \quad (3)$$

u_{safe} 는 식 (4)의 QP를 통해 정책 출력 u_{nom} 을 최소로 수정하며 식 (3)을 만족하도록 구할 수 있다. ε 은 해가 존재하지 않을 경우 제약조건 완화를 위한 슬랙 변수이며, ρ 는 충분히 큰 값으로 설정한다.

$$\begin{aligned} \min_{u_{safe}} \quad & \frac{1}{2} \|u_{safe} - u_{nom}\|^2 + \frac{\rho}{2} \|\varepsilon\|^2 \\ \text{s.t.} \quad & A(s)u_{safe} \geq b(s) - \varepsilon, \quad \varepsilon \geq 0 \end{aligned} \quad (4)$$




Fig. 2. Algorithm framework

제안 알고리즘

본 연구에서는 CBF-QP가 포함된 시스템을 하나의 MDP 환경으로 정의하고, 해당 전이 구조를 갖는 환경에서 정책을 먼저 학습한다.

Stage 1에서는 CBF-QP가 적용된 환경에서 정책을 학습한다. 정책은 항상 안전한 전이를 경험하며 해당 환경에 대한 최적 정책을 형성하나, 정책 출력과 실제 적용 입력 간 행동 불일치가 존재한다.

Stage 2에서는 MILE 기반 개입 학습을 수행한다. Stage 1에서 학습된 정책으로 롤아웃을 수행하여 상태 s , 정책 출력 u_{nom} , 안전 입력 u_{safe} , 개입 여부 ν 를 수집한다. 수집된 (s, u_{nom}) 데이터를 이용해 behavior cloning으로 mental model을 구성하고 이를 고정한다. 이후 정책은 개입 여부 ν 를 예측하고, 개입이 발생하면 u_{safe} 를 모방하도록 학습된다.

결과적으로 제안 알고리즘은 기존 행동 특성을 유지하면서 개입 구간에서 안전 동작을 직접 출력하도록 보장되며, CBF-QP 없이도 충돌을 회피하는 명령 산출이 가능하다.

시뮬레이션 결과

성능 검증을 위해 동일한 시뮬레이션 조건에서 PPO 단독 학습(100만 스텝), CBF가 적용된 환경에서의 PPO 학습(80만 스텝), 해당 정책을 CBF 제거 환경에서 실행한 경우, 그리고 MILE 기반 개입 학습을 2라운드 추가 적용한 경우를 비교하였다.

PPO 단독 학습은 더 많은 학습 스텝에도 안정적인 목표 도달에 실패하였으며, 평균 보상 역시 가장 낮게 나타났다.

CBF가 적용된 환경에서 PPO를 학습한 경우, 더 적은 학습 스텝으로 빠르게 목표 지점 도달 행동을 형성하였으며 평균 보상 또한 유의미하게 향상되었다.




Fig. 3. Trajectory comparison
(Baseline PPO, PPO+CBF, PPO+MILE)

Table. 2. Average inference time per step and mean episodic reward

모델	연산속도 ($\mu\text{s}/\text{step}$)	평균 보상
Baseline PPO	6.3 ± 4.1	81.49
PPO+CBF(CBF on)	48.4 ± 19.4	143.33
PPO+CBF(CBF off)	6.2 ± 2.8	121.26
PPO+MILE	6.1 ± 2.9	141.83

그러나 해당 정책을 CBF를 제거한 환경에서 실행하면 목표 지점 도달은 가능하나 일부 구간에서 안전 영역 침범이 발생하였다. 이는 학습 과정에서 정책의 출력과 최종 제어입력 간 불일치가 남아 있기 때문이다.

해당 정책에 대해 MILE 기반 개입학습을 적용한 결과 안전 영역 침범이 제거되었으며 평균 보상 또한 CBF 적용 환경에서의 성능에 근접하였다.

평균 연산 속도를 비교한 결과, CBF-QP를 매 스텝 계산하는 PPO+CBF(CBF on)은 연산 속도가 가장 느리며, 단일 정책 기반인 나머지 모델들은 비슷한 연산 속도를 보였다.

결론

CBF 기반 강화학습에서 발생하는 행동 불일치 문제 해결을 위해 CBF-QP가 포함된 환경을 사용한 개입 학습 기반 2단계 학습 구조를 제안하였다.

제안된 알고리즘은 기존 정책의 행동 특성을 유지하면서 충돌을 회피했으며, 반복적인 QP 계산 없이도 안전한 정책 실행이 가능함을 확인하였다.

후기

이 연구는 Airbus Institute for Engineering Research (AIER)의 지원으로 수행되었습니다.

참고문헌

- 1) Cheng, R., Orosz, G., Murray, R. M., and Burdick, J. W., "End-to-End Safe Reinforcement Learning through Barrier Functions for Safety-Critical Continuous Control Tasks," AAAI Conference on Artificial Intelligence, 2019. pp. 3387-3395.
- 2) Emam, Y., Notomista, G., Glotfelter, P., Kira, Z., and Egerstedt, M., "Safe Reinforcement Learning Using Robust Control Barrier Functions," IEEE Robotics and Automation Letters, Vol. 10, No. 3, 2025, pp. 2886-2893.
- 3) Korkmaz, Y., and Biyik, E., "MILE: Model-Based Intervention Learning," IEEE International Conference on Robotics and Automation (ICRA), 2025, pp. 15673-15679.
- 4) Notomista, G., and Egerstedt, M., "Persistification of Robotic Tasks," IEEE Transactions on Robotics, Vol. 36, No. 3, 2020, pp. 759-775.